

MINI CHALLENGE POUR LA SÉLECTION DES ÉQUIPES QUI PRENDRONT PART AU HACKATHON A LA SN 2025

PHASE DE PRÉSÉLECTION

INFORMATIONS GÉNÉRALES

Organisateur : MTDPCE

Objectif : Présélectionner les équipes pour le Hackathon Final

Nombre par equipe : 3 pers. Max (la participation des filles est encouragées)

Deadline : 05 novembre 2025

LE CHALLENGE

"Assistant IA Contextuel 100% Open Source"

Développez un système d'IA capable de répondre à des questions en utilisant **EXCLUSIVEMENT des technologies open source** sur UN sujet burkinabè de votre choix.

OBLIGATION OPEN SOURCE

Toutes les technologies utilisées doivent être open source (code source accessible, licence libre). Aucune API propriétaire payante sans alternative open source documentée.

LES 5 ÉTAPES

1. CHOISISSEZ VOTRE DOMAINE

Sélectionnez un sujet burkinabè documentable :

- Agriculture (karité, coton, mil)
- Santé (maladies tropicales, plantes médicinales)
- Éducation (système, formations)
- Culture (artisanat, musique, traditions)
- Entrepreneuriat (création, fiscalité)
- Administration (procédures)
- Tourisme (sites, patrimoine), etc.

Critère :

Information accessible en ligne + pertinence locale

2. COLLECTEZ LES DONNÉES

Minimum : 500 documents/articles/pages web

Actions :

- Scraping web (respecter robots.txt)
- Téléchargement PDFs officiels
- APIs publiques
- Compilation manuelle
- Nettoyage et normalisation

Livrables : data/corpus.json, data/sources.txt

3. SYSTÈME RAG - 100% OPEN SOURCE

Votre système doit intégrer trois composants essentiels, **tous issus de l'écosystème open source** :

A. Modèle d'Embeddings : Choisissez un modèle de transformation de texte en vecteurs numériques. Privilégiez les modèles multilingues qui supportent le français, légers (pour fonctionner en local) et bien documentés. Explorez les bibliothèques de la communauté open source spécialisées en traitement du langage naturel.

B. Base de Données Vectorielle : Sélectionnez une solution de stockage et de recherche vectorielle 100% open source. Votre choix doit permettre une indexation rapide, une recherche par similarité efficace, et une installation locale sans dépendance à des services cloud propriétaires. Comparez les options disponibles en termes de performance, simplicité d'utilisation et qualité de documentation.

C. Grand Modèle de Langage (LLM) : Optez pour un modèle de génération de texte open source que vous pouvez exécuter localement ou via une API gratuite. Évaluez les modèles disponibles selon leur taille (compatibilité avec vos ressources), leur performance en français, et leur licence d'utilisation. Les solutions locales sont fortement encouragées pour garantir l'autonomie de votre système.

Pipeline : Question → Embeddings → Recherche vectorielle → Documents → LLM → Réponse + Sources

4. INTERFACE UTILISABLE

Backend API : FastAPI, Flask (open source)

Frontend : HTML/CSS/JS vanilla, Streamlit, Gradio (tous open source)

Bonus : Application déployée (Railway, Render, HuggingFace Spaces)

5. ÉVALUATION SYSTÈME

Dataset Test : 20 questions avec réponses attendues

Métriques :

- Précision Retrieval : % documents pertinents
- Pertinence Réponse : /5
- Temps Réponse : moyenne

LIVRABLES

1. Repository GitHub PUBLIC

- README.md (2 pages max)
- data/ (corpus + sources)
- src/ (code RAG + API)
- frontend/ (interface)
- evaluation/ (tests + résultats)
- requirements.txt
- LICENSE (fichier obligatoire - MIT ou Apache 2.0 recommandé)

2. README.md obligatoire :

- Sujet choisi et justification
- Architecture technique
- Technologies open source utilisées (avec liens vers licences)
- Instructions installation
- Résultats évaluation

GRILLE D'ÉVALUATION (100 points)

- Qualité données (collecte + nettoyage): 20 pts
- Système RAG (embeddings + recherche + génération): 35 pts
- Interface utilisateur (fonctionnelle + design): 10 pts
- Évaluation (tests + métriques + analyse): 15 pts
- Documentation (README + code commenté): 10 pts
- Respect 100% open source: 5 pts

- Creativite : 5 pts

Bonus:

- Déployé en ligne : +5 pts
- Vidéo démo : +5 pts
- Tests automatisés : +3 pts
- Support multilingue (français + langue locale) : +5 pts

RÈGLES IMPORTANTES

Autorisé ET Encouragé

- ChatGPT, Claude, Copilot comme assistants de développement
- TOUTES bibliothèques/frameworks OPEN SOURCE
- Modèles IA open source (Llama, Mistral, BERT, etc.)
- Outils de développement open source
- APIs gratuites avec limites documentées

OBLIGATOIRE

- PRIVILÉGIER L'OPEN SOURCE dans TOUS vos choix
- Documenter chaque technologie utilisée (nom + licence + lien)
- Fichier LICENSE dans votre repo
- Comprendre CHAQUE ligne de code
- Commits Git progressifs
- Respecter les licences des outils utilisés

Interdit

- APIs propriétaires payantes sans alternative open source
- Plagiat de projets existants
- Code non compris (copier-coller aveugle)
- Masquer l'usage de solutions propriétaires
- Oublier de citer les licences

PRÉSENTATION & ENTRETIEN TECHNIQUE - ÉLIMINATOIRE

10 minutes par équipe :

- Expliquez votre pipeline RAG (3 min)
- Pourquoi ces technologies open source? (2 min)
- Expliquez cette fonction de votre code (3 min)

- Modifiez ce paramètre en direct (2 min)

! Incapacité à expliquer = DISQUALIFICATION

STRATÉGIE GAGNANTE

- Commencez simple : pipeline basique fonctionnel
- Documentez pendant le développement
- Testez en continu
- Commits Git réguliers

PIÈGES À ÉVITER

- Sujet trop large
- Sur-ingénierie
- Pas de LICENSE file
- Documentation absente

POURQUOI L'OPEN SOURCE?

- Souveraineté technologique - Vous contrôlez votre code
- Apprentissage - Accès au code source
- Pérennité - Pas de dépendance à des services payants
- Transparence - Reproductibilité scientifique
- Communauté - Contribution au bien commun

Bonne chance à tous ! Que le meilleur système open source gagne !